数据集说明：类型、格式、字段与磁盘组织

> 本文说明本项目**用了哪些数据、原始格式长什么样、我们把它变成了什么、放在磁盘什么位置、谁读写谁。**
> 指标口径见 指标名词表，运行记录见 ../reports/runlog.md。
> 所有路径均相对于项目根目录 `/Users/zhouchenyu/Desktop/Code/TibetOCR_ASR`。

---

0. 总览

数据集	用途	规模	许可	原始格式	落盘位置
BDRC Tibetan OCR Benchmark	OCR 评测（参考+图）	472 页 / 122MB 图像	CC0	1 个 parquet（图像字节内嵌）	`data/ocr/`
NICT-Tib1 (test split)	ASR 主评测（拉萨朗读）	1,547 条 / 185.5 分钟 / 3 说话人	CC-BY-4.0	1 个 parquet（音频字节内嵌）	`data/asr/nict_test/`
OpenPecha / Monlam 语音基准	ASR 跨域泛化（8 领域）	8,367 条全量；本项目抽 160 条 / 8.9 分钟	MIT	1 个 CSV（音频是外链 URL）	`data/asr/openpecha_bench/`

三个数据集有一个共同特点：**元数据与媒体内容被"打包在同一个文件里"**（parquet 的 `struct<bytes, path>` 字段），或者"元数据在仓库、媒体在外部 CDN"（OpenPecha）。因此数据准备脚本必须先做一次**解包/转码**，把训练与推理代码需要的"文件系统形态"建出来。

---

1. 磁盘布局

```
TibetOCR_ASR/                                         总量 ≈ 2.5GB（含 .venv）
├── data/                                             ≈ 960MB   数据集（.gitignore）
│   ├── ocr/                                          ≈ 249MB   ← 数据集 1
│   │   ├── hf/                                       ≈ 123MB    原样下载（HuggingFace 本地快
照）
│   │   │   ├── data/test-00000-of-00001.parquet       121,619,456 B  472 页 + 图像 + 转写
│   │   │   ├── runs/compute_cer.py                          5,324 B  官方打分脚本
│   │   │   ├── runs/ground_truth.csv                    1,257,403 B  官方 GT（botok 已规范
化）
│   │   │   ├── runs/requirements.txt                           16 B
│   │   │   └── .cache/huggingface/…                                  下载锁 / etag / 校验
元数据
│   │   ├── images/                                    ≈ 122MB    472 个 {id}.png（从
parquet 解出）
│   │   ├── ground_truth.csv                             1,257,403 B  472 行
id,transcription
│   │   ├── metadata.csv                                    39,035 B  472 行，8 列分桶信息
│   │   ├── official/                                   ≈ 1.3MB    官方口径副本（只读参考）
│   │   │   └── compute_cer.py / ground_truth.csv / requirements.txt
│   │   ├── sample_ids.json                                    829 B  pilot 6 页 / sample
60 页
│   │   └── stats.json                                         335 B  技术/文字类型分布
│   └── asr/                                           ≈ 712MB   ← 数据集 2 + 3
│       ├── hf/                                       ≈ 338MB
│       │   ├── data/test-00000-of-00001.parquet      334,751,877 B   NICT 1,547 条
│       │   └── test.csv                                2,964,580 B   OpenPecha 全量清单
8,367 行
│       ├── nict_test/                                ≈ 357MB   ← 数据集 2
│       │   ├── wav/                                  ≈ 356MB   1,547 × nict_XXXXX.wav
│       │   ├── metadata.csv                              646,608 B   1,547 行
│       │   └── sample_ids.json                            33,281 B   sample 300 / all
1547
│       └── openpecha_bench/                           ≈ 17MB   ← 数据集 3
│           ├── wav/                                    ≈ 17.2MB  160 个原始文件名 .wav
│           ├── metadata.csv                               45,072 B   160 行
│           └── sample_ids.json                             7,094 B
├── outputs/                                         ≈ 9MB     每次运行的预测与记录
 (.gitignore)
├── reports/                                         ≈ 3MB     汇总表 + 样例 + 本文
├── tessdata/bod.traineddata                          8,623,846 B  Tesseract 藏文模型
 (.gitignore)
├── docs/                                            ≈ 60 KB
├── scripts/                                         ≈ 130 KB
└── .venv/                                           ≈ 1.6GB   Python 依赖（与数据无关）
```

> 注意：本文按**十进 MB** 写（1 MB = 10^6 B），而 `du -sh` 显示的是 MiB（1 MiB = 1.048 MB）并按 4KB 块取整，所以 `du` 会显示 `data/ocr ≈ 237M`、`data ≈ 920M`。二者相差约 5%，属正常。
> `data/`、`outputs/`、`tessdata/`、`.venv/` 都在 `.gitignore` 里，**不会进版本库**。

---

2. 数据集 1：BDRC 藏文 OCR 基准

2.1 来源

项目	内容
仓库	https://huggingface.co/datasets/BDRC/tibetan-ocr-benchmark
版本	主分支快照（2026-11-07 changelog：47 页 synthetic 重生成、11 页 Uchen/Ume 修正）
许可	**CC0-1.0**（可自由使用，含商用）
规模	472 页（另有 1,070 页私有集不公开）
标注方	Dharmaduta
配套	46 个系统的历史预测（`runs/predictions/*.csv`）+ 官方 CER 脚本

2.2 原始格式：单个 parquet

```
data/ocr/hf/data/test-00000-of-00001.parquet   121,619,456 B   472 行 × 9 列   2 个 row
group
schema:
  id             string
  transcription  string
  technology     string
  script         string
  script_4       string
  period         string
  rarity         string
  legibility     string
  image          struct<bytes: binary, path: string>
```

`image` 是嵌套结构体（HuggingFace `datasets` 的 Image 特性约定）：`bytes` 是完整图像文件字节（原样，未解码），`path` 是匿名化文件名（就是 4 位页码，无扩展名）。用 pandas 读出来是 `dict`：

```
>>> df.iloc[0]["image"].keys()
dict_keys(['bytes', 'path'])
>>> len(df.iloc[0]["image"]["bytes"]), df.iloc[0]["image"]["path"]
(195521, '0002')
```

这就是为什么数据准备脚本要用 `img_path.write_bytes(row.image["bytes"])` 而不是"复制文件"。

2.3 字段字典（原始 9 列）

列	类型	含义	取值 / 示例	为什么有用
`id`	string	匿名化页码，4 位补零	`"0002"` … `"1075"`（**不连续**，472 个里有很多空洞）	与官方 `ground_truth.csv`、`predictions/*.csv` 对齐的唯一键
`transcription`	string	人工转写，仅正文框（不含页边、页码）	`༄༅། །སྔོ་ལྡང་སྨྱུ་གུ་ཡིས་ཁྲབ་ཅིང་། …`	评测参考；**已在数据集构建时做过 botok 规范化**
`technology`	string	页面制作工艺	`manuscripts`(209) / `digital_fonts`(133) / `blockprints`(91) / `modern`(17) / `metal_types`(17) / `typewriters`(5)	分层抽样与分桶报告的主维度
`script`	string	粗粒度文字体系	`Uchen`(238) / `Ume`(193) / `Transitional`(21) / 混排 `Uchen+Ume` 等(20)	判断字形体系难度
`script_4`	string	细粒度书写风格	`Uchen` / `Pedri` / `Gyuyig` / `Druma` / `Tsugdri` / `Danyig` / `Non-applicable`	更细的风格分析（本项目未用于报告）
`period`	string	古文字学年代	`Medieval (15)-present`	判断历史手稿难度
`rarity`	string	该书写风格的常见度	`4 - very common` … `1 - rare`	判断指标是否被稀有风格左右
`legibility`	string	清晰度评级	`4 - Excellent`(293) / `3 - Good`(124) / `2 - Fair`(42) / `1 - Poor`(12) / `0 - Illegible`(1)	解释失败原因；抽样时避开最差页做 pilot
`image`	struct	图像字节 + 文件名	`{bytes: 195521 B, path: "0002"}`	实际输入

转写约定（影响 CER，必须知道）：只转写正文框；保留正字法缩写；以下占位符出现在 GT 中——

符号	含义	本项目处理
`I`	不可辨认	打分前删除（BDRC 协议）
`B`	破损纸面	删除
`S`	被划掉	删除
`D` / `K`	空行母文字（dakini script）	删除
`O`	装饰性图案	删除
`( )`	抄写者后补内容	按普通字符保留

即 `PLACEHOLDERS = frozenset("KOBIS")` 这个集合的来源。

2.4 我们导出的形态

文件	行/个	内容	说明
`images/{id}.png`	472	单页图像	**原样字节**，未转码（见 2.5）
`ground_truth.csv`	472	`id,transcription`	与官方 `runs/ground_truth.csv` **md5 完全相同**（`ed10b58b…`），因为 parquet 里的转写本来就是规范化过的
`metadata.csv`	472	`id,technology,script,script_4,period,rarity,legibility,n_chars`	供分桶统计与抽样；`n_chars` 是本项目新增列（转写字符数，用来解释耗时与 CER 长度效应）
`sample_ids.json`	-	`{"pilot":[6 个 id], "sample":[60 个 id]}`	抽样结果，随机种子 42，可复现
`stats.json`	-	技术/文字类型计数	快速核对分布
`official/`	3 个文件	官方脚本 + GT + 依赖	**只读口径基准**，`score_ocr.py` 复刻其逻辑，`verify_data.py` 用它校验

`ground_truth.csv` 样例（一行）：

```
id,transcription
0002,"༄༅། །སྔོ་ལྗང་སྨྱུ་གུ་ཡིས་ཁྱབ་ཅིང་། །བཏབ་པའི་ལོ་ཏོག་ལེགས་པའི་རྩ་བདེ་ཚུགས་བྱུང་། …"
```

> 文件是 **UTF-8 无 BOM**（`csv.DictWriter` 默认行为），字段带引号是因为转写里有换行与逗号。

`metadata.csv` 样例：

```
id,technology,script,script_4,period,rarity,legibility,n_chars
0002,blockprints,Uchen,Uchen,Medieval (15)-present,4 - very common,2 - Fair,965
0003,digital_fonts,Uchen,Uchen,Medieval (15)-present,4 - very common,4 - Excellent,811
```

2.5 图像本身的性质（实测）

项目	数值
数量	472
分辨率	宽中位 **2220 px**（526–11712）、高中位 **881 px**（227–5957）
面积	中位 **1.86 MP**（最大约 70 MP 的长卷）
色彩模式	`RGB` 389、`1`（二值）48、`L`（灰度）34、`LA` 1
真实编码	**JPEG 415 个、PNG 57 个**

⚠️ **容器扩展名与真实编码不一致**：所有文件都命名为 `{id}.png`，但其中 415 个实际是 JPEG 字节（因为脚本按原样保存 `image["bytes"]`，而数据集里的原图多数是 JPEG，只是 `path` 字段不含扩展名）。

- **影响**：无。PIL 与 Tesseract 都按文件头魔数识别格式，不看扩展名；`verify_data.py` 已抽查解码通过。
- 若确实需要真 PNG（例如某些只认扩展名的工具），重新编码即可：

```
./.venv/bin/python - <<'PY'
from PIL import Image; from pathlib import Path
for p in Path("data/ocr/images").glob("*.png"):
    im = Image.open(p)
    if im.format != "PNG":
        im.save(p, format="PNG")
PY
```

2.6 抽样文件结构

```
{
  "pilot":  ["0567", "0042", "0187", "0097", "0725", "0706"],
  "sample": ["0011", "0029", "0039", "… 共 60 个 …"]
}
```

- `pilot`：每种制作工艺各 1 页、优先短而清晰的页面，用于跑通链路 + 测速。
- `sample`：按 `technology` 配额 18/14/14/5/5/4，层内交替取 Uchen/Ume，共 60 页。
- `run_ocr.py --split pilot|sample|all` 直接读这个文件；`all` 表示全部 472 页。

3. 数据集 2：NICT-Tib1（test split）

3.1 来源

项目	内容
仓库	https://huggingface.co/datasets/billingsmoore/nict-tib1
原始语料	NICT-Tib1（Soky, Gong & Li, 2022），拉萨藏语朗读新闻，20 位说话人
许可	**CC-BY-4.0**
划分	train 15,099 条（17 人）/ **test 1,547 条（3 人，与训练说话人不重叠）**
为什么用它	与 Tibetan ASR 论文（IEEE Access 2026）的 14 个 checkpoint **同一测试集**，可直接对比论文数字

3.2 原始格式：单个 parquet

```
data/asr/hf/data/test-00000-of-00001.parquet   334,751,877 B   1,547 行 × 3 列   16 个 row group
schema:
  audio          struct<bytes: binary, path: string>
  transcription  string
  speaker_id     string
```

列	含义	示例
`audio.bytes`	完整 wav 文件字节（16 kHz / 单声道 / PCM_16）	平均 ~230KB（总 356MB）
`audio.path`	原始文件名 `{speaker}_{utt}.wav`	`074_344.wav`
`transcription`	逐句转写（保留 tsheg/shad，含数字与专名）	`ཉིས་སྟོང་བཅུ་བདུན་ལོའི་རྒྱལ་སྤྱིའི་…`
`speaker_id`	说话人编号	`074` / `019` / `070`

3.3 落盘格式与命名

项目	内容
路径	`data/asr/nict_test/wav/{id}.wav`
命名	**`nict_{parquet 行号:05d}.wav`**：`nict_00000.wav` … `nict_01546.wav`
编码	16 kHz、单声道、`PCM_16`（RIFF/WAV）
为什么重命名	原始名 `074_344.wav` 只在同一说话人内唯一，跨 split/跨版本可能重复或变号；顺序索引 + 保留原始名到 parquet，两边都能追溯
代价	索引依赖 **parquet 行序**。`metadata.csv` 是唯一的"索引 → 内容"映射，请勿只保留 wav
转码	用 `librosa.load(..., sr=16000, mono=True)` 后再写回，保证采样率/声道统一（本数据集原本就是 16k，属幂等操作）

3.4 我们导出的 `metadata.csv`（7 列，1,547 行）

列	含义	示例
`id`	顺序索引	`nict_00000`
`audio_path`	**相对项目根**的音频路径	`data/asr/nict_test/wav/nict_00000.wav`
`transcription`	参考转写	`ཉིས་སྟོང་བཅུ་བདུན་ལོའི་…`
`speaker`	说话人	`074`
`duration`	时长（秒，读取音频头得到）	`9.24`
`dataset`	数据集标记	`nict`
`dept`	领域标记（恒为 `news`）	`news`

`sample_ids.json`：

```
{"sample": ["nict_00019", "… 共 300 个 …"], "all": ["nict_00000", "… 共 1547 个 …"]}
```

- `sample`：按说话人各抽 100 条（`800/400/347` → 各 100），共 300 条。所有 Whisper 类模型都跑这个子集；
- `all`：全量，CTC 模型（很快）跑全量；
- `summarize_asr.py` 会把全量结果过滤到 `sample`，保证所有模型在同一 300 条上比较。

3.5 统计

项目	数值
条数 / 总时长	1,547 条 / **185.5 分钟**
单条时长	均值 7.19s、中位 6.56s、p90 10.51s、最大 18.87s
说话人	`074`: 800、`019`: 400、`070`: 347
参考长度	中位 106 字符、p90 175、最大 296
总字节	wav 356MB（parquet 里压缩为 335MB）

> 关键含义：单条最长约 19 秒，但参考长度可达 296 字符 → **Whisper 的 448 token 上限（约 145 字符）会截断约 1/5 的句子**，这是数据本身带来的限制，不是模型 bug。

---

4. 数据集 3：OpenPecha / Monlam 语音基准

4.1 来源

项目	内容
仓库	https://huggingface.co/datasets/openpecha/tibetan-voice-benchmark
制作方	Monlam AI × OpenPecha（2024-07-15 取数）
许可	**MIT**
规模	8,367 条 / 7.36 小时 / 8 个领域
转写质量	每条至少一名复核者；`grade` 3 表示通过质检团队
音频位置	**不在仓库里**，而是 CloudFront 直链（`https://d38pmlk0v88drf.cloudfront.net/wav16k/{file_name}.wav`）

4.2 原始格式：单个 CSV（含外链）

```
data/asr/hf/test.csv   2,964,580 B   8,367 行 × 8 列
```

列	含义	示例
`file_name`	唯一标识（也是音频 URL 的文件名）	`STT_AB00277_0455_2502107_to_2503882`
`uni`	藏文 Unicode 转写（评测用）	`གཟུགས་སྐུ་སྤྱི་ཙམ་ལ་སྤྲུལ་སྐུ་དང་།`
`wylie`	威利转写（拉丁字母，本项目未用）	`gzugs sku spyi tsam la sprul sku dang /__`
`url`	音频直链	`https://d38pmlk0v88drf.cloudfront.net/wav16k/….wav`
`dept`	领域代码（见下表）	`STT_AB`
`grade`	转写质量等级 1–3	`3`
`char_len`	转写字符数	`36`
`audio_len`	音频时长（秒）	`1.775`

这是与前面两个数据集**结构上最大的不同**：元数据在 HF 仓库，媒体在外部 CDN。所以准备脚本要 `pandas` 读 CSV → `requests.get(url)` 下载 → 落盘。

4.3 下载与抽样流程

```
test.csv  ──按 dept 分组──> 每组优先取 grade≥2 ──随机抽 20 条──> 并发下载 wav(8 线程)
           └─> data/asr/openpecha_bench/wav/{file_name}.wav    （保留原始文件名）
           └─> data/asr/openpecha_bench/metadata.csv
```

- 抽样：8 领域 × 20 条 = **160 条**（随机种子 42）。
- 命名：**保留原始 `file_name`**（全局唯一，含领域前缀 `STT_AB…`）。
- 若单条下载失败只跳过该条并告警（`status` 会在后续打分中显露为缺失）。
- 需要全量时：`--openpecha-per-dept 2000`（会下载全部 8,367 条、约 7.4 小时音频）。

4.4 领域代码对照（`dept`）

代码	英文	中文	本样本条数 / 总时长	平均转写字符数
`STT_AB`	Audio book	有声书	20 / 49.5s	33.5
`STT_CS`	Children Speech	儿童语音	20 / 82.6s	46.7
`STT_HS`	History	历史	20 / 65.0s	52.9
`STT_MV`	Tibetan Movies	电影	20 / 109.0s	47.4
`STT_NS`	Natural Speech	自然口语	20 / 60.4s	57.4
`STT_NW`	News	新闻	20 / 69.7s	54.4
`STT_PC`	Podcast	播客	20 / 58.9s	59.8
`STT_TT`	Tibetan Teachings	佛法开示	20 / 41.6s	44.2

4.5 我们导出的 `metadata.csv`（8 列，160 行）

列	含义	示例
`id`	原始 `file_name`	`STT_AB00189_0080_275947_to_278950`
`audio_path`	相对项目根路径	`data/asr/openpecha_bench/wav/STT_AB00189_….wav`
`transcription`	`uni` 列	`ཉན་རང་གི་ཐེག་པ་ཞེས་སྦྱད་ན`
`speaker`	空（该数据集不提供说话人标注）	``
`duration`	音频头里的真实时长	`3.003`
`dataset`	标记	`openpecha`
`dept`	领域代码	`STT_AB`
`grade`	转写质量等级	`3`

统计：160 条 / **8.94 分钟** / 全部 `grade=3`（本样本恰好都命中质检通过的条目）。

---

5. 文件格式速查

格式	出现在哪	关键特性	读取方式
Parquet	`data/{ocr,asr}/hf/data/*.parquet`	列式、Schema 内嵌、可存二进制；`struct<bytes,path>` 承载媒体	`pandas.read_parquet`
CSV（UTF-8，无 BOM）	`ground_truth.csv`、`metadata.csv`、`test.csv`	文本含换行/逗号 → 必须加引号	`pandas.read_csv(dtype={"id": str})`
WAV（RIFF/PCM_16）	`data/asr/*/wav/*.wav`	16 kHz、单声道、16 bit；无损、可随机定位	`soundfile.info` / `librosa.load(sr=16000)`
PNG/JPEG（字节）	`data/ocr/images/*.png`	**扩展名不等于真实编码**（415 JPEG + 57 PNG）	`PIL.Image.open`
JSON	`sample_ids.json`、`stats.json`、`run.json`	结构与参数快照	`json.load`
Traineddata	`tessdata/bod.traineddata`	Tesseract LSTM 模型包	`--tessdata-dir tessdata`

CSV 的引号规则很重要：OCR 输出保留换行（prompt 要求 "Preserve line breaks"），一行预测可能跨多行文本。因此 `run_ocr.py` 写 `predictions.csv` 时用 `csv.QUOTE_ALL`，否则重读会错行。

6. 数据流水线：谁生产、谁消费

```
                      ┌──────────────────────────────────────────────┐
 HuggingFace Hub ────>│ prepare_ocr_data.py / prepare_asr_data.py    │
 (hf_hub_download     │  解包 parquet / 下载 CDN / 转码 / 抽样        │
  local_dir=data/*/hf)└───────────────┬──────────────────────────────┘
                                      │
        ┌─────────────────────────────┴───────────────────────────┐
        ▼                                                         ▼
 data/ocr/images + ground_truth.csv + metadata.csv
data/asr/{nict_test,openpecha_bench}/
 + sample_ids.json + stats.json + official/                  wav/ + metadata.csv +
sample_ids.json
        │                                                         │
        ▼                                                         ▼
   run_ocr.py  (yigdzin │ tesseract)                        run_asr.py (6 个模型)
        │                                                         │
        ▼                                                         ▼
 outputs/ocr/<run_id>/                                     outputs/asr/<run_id>/
   predictions.csv  (id,transcription)                       predictions.csv
   details.csv      (+seconds,status,technology,script)      run.json
   run.json         (参数/设备/耗时/错误数)                    │
        │                                                         │
        ▼                                                         ▼
   score_ocr.py                                             score_asr.py
        │                                                         │
        ├─> details_scored.csv (+gt,cer,catastrophic)             ├─>
predictions_scored.csv (+cer,swer,rtf)
        └─> reports/ocr_results.csv                               ├─>
reports/asr_results.csv
                                                                  └─> summarize_asr.py →
reports/asr_final_*.csv
        │                                                         │
        └───────────────> make_samples.py ────────────────────────┘
                          reports/samples/{ocr,asr}/ + *.md
```

文件	生产者	消费者	备注
`data/ocr/hf/**`	`hf_hub_download`	`prepare_ocr_data.py`	原始快照，不直接给模型用
`data/ocr/images/`	`prepare_ocr_data.py`	`run_ocr.py`	按 `id` 命名
`data/ocr/ground_truth.csv`	`prepare_ocr_data.py`	`score_ocr.py`、`verify_data.py`	与官方一致
`data/ocr/metadata.csv`	同上	`run_ocr.py`（分桶字段）、`score_ocr.py`	分技术与文字的统计来源
`data/ocr/sample_ids.json`	同上	`run_ocr.py --split`	可复现抽样
`data/ocr/official/**`	`hf_hub_download`	`verify_data.py`、人	口径基准（只读）
`data/asr/hf/**`	`hf_hub_download`	`prepare_asr_data.py`	NICT parquet + OpenPecha CSV
`data/asr/*/wav/`	`prepare_asr_data.py`	`run_asr.py`	16k mono PCM_16
`data/asr/*/metadata.csv`	同上	`run_asr.py`、`score_asr.py`、`make_samples.py`	含 `audio_path`
`data/asr/*/sample_ids.json`	同上	`run_asr.py --limit`、`summarize_asr.py`	统一子集
`outputs/ocr/<run>/predictions.csv`	`run_ocr.py`	`score_ocr.py`	`id,transcription`，QUOTE_ALL
`outputs/ocr/<run>/details*.csv`	`run_ocr.py` / `score_ocr.py`	人、`make_samples.py`	逐页记录
`outputs/asr/<run>/predictions*.csv`	`run_asr.py` / `score_asr.py`	人、`summarize_asr.py`、`make_samples.py`	逐条记录
`outputs/logs/*.log`	各脚本重定向	人	原始 stdout

---

7. 模型权重放在哪（不在项目目录里）

模型**没有**下载到 `data/`，而是走 HuggingFace 默认缓存：

```
~/.cache/huggingface/
├── hub/
│   ├── models--BDRC--tibetan-ocr/
│   │   ├── snapshots/<commit-sha>/model.safetensors -> ../../blobs/dc/dca65…   ← 软链接
│   │   └── refs/main
│   └── models--<org>--<name>/…
├── hub/blobs/XX/<sha256>            ← 真实权重（按内容寻址，去重）
└── xet/                             ← xet 分块传输缓存（下载加速用，可删）
```

模型	权重文件	大小
`BDRC/tibetan-ocr`（Yigdzin）	`model.safetensors`	**1.63 GB**
`openpecha/general_stt_base_model`	`model.safetensors`	1.26 GB
`billingsmoore/…-whisper-small`	`model.safetensors`	967 MB
`tenzin/whisper-small-tibetan`	`model.safetensors`	967 MB
`billingsmoore/…-wav2vec2-base`	`model.safetensors`	378 MB
`billingsmoore/…-whisper-base`	`model.safetensors`	290 MB
`billingsmoore/…-whisper-tiny`	`model.safetensors`	151 MB
`openai/whisper-{tiny,base,small}`	仅 tokenizer/feature-extractor	各 ~4 MB
合计（`~/.cache/huggingface`）		**≈ 6.5 GB**

为什么会疑惑"模型目录只有 460KB"：`snapshots/` 里都是软链接，真实字节在 `hub/blobs/`。`du -sh` 默认不跟随软链接，所以看起来很小。检查真实占用用：

```
du -sh ~/.cache/huggingface/hub/blobs
```

换位置：设置 `HF_HOME=/path/to/big-disk`（或 `HF_HUB_CACHE`）后再跑脚本即可，代码无需修改。

---

8. 路径约定（容易踩的三个点）

1. **`metadata.csv` 里的 `audio_path` 是相对项目根目录**（如 `data/asr/nict_test/wav/x.wav`），不是相对 csv 所在目录。
   `run_asr.py` 用 `ASR_DIR.parent.parent`（= 项目根）拼接绝对路径；若移动数据目录，这两个常量要一起改（`scripts/common.py` 顶部）。
2. **OCR 侧只用 `id`，不存图片路径**。`run_ocr.py` 按 `data/ocr/images/{id}.png` 约定拼路径，所以**改文件名 = 改约定**，需同步改代码。
3. **`sample_ids.json` 是"数据与实验的契约"**。改了抽样必须重跑所有模型，否则跨模型对比失效（`summarize_asr.py` 也会过滤不到旧样本）。

---

9. 存储核算

项目	大小	可删?
`data/`（三套数据集 + 中间产物）	960 MB	可删，用脚本重下
`outputs/`（14 个 run 的预测与日志）	9 MB	建议保留（测试记录）
`reports/`（汇总表、样例、文档）	3 MB	建议保留
`tessdata/`（Tesseract bod）	8.6 MB	可删，重下 1 条命令
`.venv/`（依赖）	1.6 GB	可删，`pip install -r requirements.txt`
`~/.cache/huggingface/`（模型）	6.5 GB	可删，首次运行会重下
合计	**≈ 9.1 GB**	-

只保留"结论可复现"的最小集：`scripts/` + `requirements.txt` + `reports/` + 文档（约 3.2 MB）。

---

10. 重建与完整性校验

10.1 从零重建

```
# 只重建 OCR（约 10 秒 + 121MB 下载）
./.venv/bin/python scripts/prepare_ocr_data.py --force

# 只重建 ASR（约 1 分钟 + 335MB + CDN 下载）
./.venv/bin/python scripts/prepare_asr_data.py

# Tesseract 模型
curl -L -o tessdata/bod.traineddata \
  https://github.com/tesseract-ocr/tessdata_best/raw/main/bod.traineddata
```

- `prepare_ocr_data.py --force` 会覆盖已导出的图片（不加则跳过已存在文件，只补缺）。
- 抽样可复现：`--seed 42`（默认），若改种子会生成不同的 `sample_ids.json`，需要重跑实验。
- OpenPecha 的音频来自外部 CDN，**若链接失效，脚本会跳过该条并告警**；重新运行时只会补下缺失文件。

10.2 校验

```
./.venv/bin/python scripts/verify_data.py
```

实际输出（2026-11-12，全部通过）：

```
--- ocr ---
PASS  OCR: 472 page images  (472 files)
PASS  OCR: ground_truth ids unique
PASS  OCR: ground_truth ids == metadata ids
PASS  OCR: image files == ground_truth ids
PASS  OCR: every page has transcription
PASS  OCR: sample images decodable  (first 40 checked, 0 broken)
PASS  OCR: prepared GT == official normalised GT  (0/472 differ)
PASS  OCR: official scorer present
PASS  OCR: tesseract bod model present
PASS  OCR: sample ids  (pilot 6 / sample 60)
PASS  OCR: sample ids unique and in GT
--- nict ---
PASS  NICT: 1547 test utterances  (1547)
PASS  NICT: 1547 wav files  (1547)
PASS  NICT: ids unique
PASS  NICT: wav names == metadata ids
PASS  NICT: 16 kHz  (50 checked)
PASS  NICT: mono  (50 checked)
PASS  NICT: metadata duration matches audio  (max diff 0.0000s)
PASS  NICT: every utterance has transcription
PASS  NICT: 3 speakers (disjoint from train)  (019, 070, 074)
PASS  NICT: sample ids  (sample 300 / all 1547)
PASS  NICT: sample ids in metadata
--- openpecha ---
PASS  OpenPecha: 160 sampled clips  (160)
PASS  OpenPecha: wav per clip  (160)
PASS  OpenPecha: ids unique
PASS  OpenPecha: 8 domains x 20
PASS  OpenPecha: all grade-3 (QC) transcriptions
PASS  OpenPecha: every clip has transcription
PASS  OpenPecha: 16 kHz mono  (20 checked)
============================================================
all checks passed
```

它检查的是**"我们的导出"与"官方/源数据"是否一致**，而不是模型精度：

检查项	目的
id 集合三方一致（图片 / GT / metadata）	防止解包时漏页或错位
我们的 GT vs 官方 GT（逐条 prepare 后比较）	确认没有改动参考文本（实测 0/472 差异）
音频采样率/声道/时长与 metadata 一致	防止转码错误导致"看起来能跑但指标错"
抽样 id 是子集且数量正确	防止改抽样后实验不可比
OpenPecha 全为 grade=3、8 领域各 20	防止抽样逻辑漂移

---

11. 已知限制与坑

项	说明	影响
OCR 图像扩展名 ≠ 真实编码	415 个 JPEG 命名为 `.png`	无（按魔数识别）；需真 PNG 见 2.5
OCR id 不连续	0002–1075 之间大量空洞（匿名化）	不能用 `range()` 遍历，必须读 `metadata.csv`
OCR 仅公开 472/1070 页	私有 holdout 未公开	与榜单全量数字只能比"同一子集"
NICT 仅 3 位说话人	官方设计（防止说话人泄漏）	结论对"新说话人"的泛化置信度有限
NICT id 依赖 parquet 行序	`nict_00000` 是行号，不是原文件名	必须保留 metadata.csv；原文件名在 parquet `audio.path`
Whisper 448 token 上限	1/5 句子参考长度 >145 字符	长句截断，需报告 ≤150 字子集（见指标名词表）
OpenPecha 音频走外部 CDN	CloudFront 直链可能变动/限速	下载失败会跳过；重建时补下
OpenPecha 与 openpecha 训练集可能重叠	同源数据	该数据集上的分数应视为乐观上界
参考转写已规范化	parquet 里的 GT 是 botok-normalized	自己再跑一遍规范化反而可能引入 1 处差异（实测 1/472），所以 ref 侧只做 `prepare_text`
方言覆盖	三套数据都是卫藏（拉萨）中心方言	安多/康巴结论不可外推