实测结果

> 环境：Apple M4（10 核 GPU）/ 16GB / macOS 27.2 / torch 2.15.0 (MPS) / transformers 5.22.2。
> 所有数字均可用 `scripts/` 下的脚本复现；原始预测与运行元数据在 `outputs/`，汇总表在 `reports/`。
> 测试时间：2026-11-12 20:40 – 23:10（北京时间）。
> 文中 CER / SWER / RTF / 灾难页 / pp / token 等术语的含义与计算方式见 指标名词表。

---

1. OCR

1.1 总览

引擎	页面	mean CER	median CER	灾难页(>50%)	耗时/页
BDRC/tibetan-ocr（Yigdzin 1），pilot	3	4.41%	1.50%	0%	13.7s
BDRC/tibetan-ocr（Yigdzin 1），60 页分层样本	60	**2.50%**	**1.01%**	**0%**	36.4s（中位 33.3s）
Tesseract 5 + `bod`	60	53.52%	56.06%	53.3%	3.3s

> 口径：BDRC 官方协议（botok 规范化 → 去空白/折叠 tsheg/去占位符 → 字符级 Levenshtein，单页封顶 1.0）。
> 60 页为按技术分层的子集，绝对值不能与榜单全量 472 页的 3.21% 直接比较；作为参考，同口径下榜单第一名 Yigdzin 为 3.21%（mean）、0.96%（median）。

1.2 分技术/文字类型

技术	页数	Yigdzin mean CER	Tesseract mean CER
数字字体（digital_fonts）	14	**0.61%**	47.17%
金属活字（metal_types）	5	**0.33%**	21.45%
木刻（blockprints）	14	**1.23%**	59.16%
现代印刷（modern）	5	**1.34%**	27.02%
手稿（manuscripts）	18	**3.61%**	75.11%
打字机（typewriters）	4	**12.77%**	32.08%

文字类型	页数	Yigdzin mean CER
Uchen（有头体）	27	2.7%
Ume（无头体）	8	1.8%
Transitional（过渡体）	9	0.8%
Uchen+Ume 混排	5	4.5%–7.3%

1.3 分析与失败模式

- Yigdzin 在 **60 页中 59 页优于 Tesseract**，整体 CER 相差约 21 倍。
- 最好的场景是数字字体/金属活字/木刻（<1.5%），最差是**打字机**（12.8%）：
    - `0764`（打字机，CER 32.2%）：整体正确，但 `འཛིན→འཛིགས` 这类字形误读在 1300 字长文中累积；末尾可能丢行。
    - `0408`（打字机，CER 15.1%）：出现整段内容错位/漏行，属于长页面的版序问题。
    - `0084`（手稿，CER 10.6%）：咒语/梵文转写（`ཨོཾ་པི་ཏྲི་ལི...`）中少量音节差异在长重复文本中放大。
- 没有出现重复循环（DRY 生效，灾难页 0）。
- 速度与页面尺寸强相关：行条图（1500×344）约 14s/页；整页（~1000×1500）约 30–40s；最长一页 115s（1,920 字符）。60 页平均 36.4s（中位 33.3s，无并发时约 30s）。
- 显存峰值约 2.9GB（bf16），16GB 内存机器可安全运行。

1.4 工程要点

1. **必须显式 `use_cache=True`**：仓库自带 `generation_config.use_cache=false`，直接按模型卡示例在 M4 上单页 >300s；开启后输出逐字节一致，单页降到 ~30s（行条图 14s）。
2. **必须清零 `mm_token_type_ids`**（sequential M-RoPE），否则结构化页面会漏行/串行。
3. DRY 抗重复参数 `mult=0.8, base=1.75, allowed_length=12` 在本样本上有效且未损伤正常页面。
4. 无 CUDA 环境下 MPS + bf16 工作正常，未回退 CPU。

逐页对比见 `reports/ocr_per_page.csv`，样例见 `reports/samples/ocr_samples.md`。

---

2. ASR

2.1 NICT-Tib1（拉萨藏语朗读新闻，统一 300 条子集）

评测集：从 1,547 条 test 中按 3 位说话人各抽 100 条（共 300 条，35.4 分钟）。所有模型在同一子集上比较；CTC 模型额外跑过全量 1,547 条以验证口径。

模型	参数	论文 CER / SWER	实测 CER	实测 SWER	≤150 字 CER	RTF	峰值内存
wav2vec2-base	94M	7.45% / 27.47%	**7.25%**	28.56%	7.35%	**0.023**（43× 实时）	1.30GB
openpecha-general	~315M	~12.6%（社区）	7.78%	29.09%	7.80%	0.049	1.75GB
whisper-tiny	39M	15.60% / 29.75%	11.57%	27.84%	8.07%	0.251	1.15GB
whisper-base	74M	14.17% / 26.00%	10.22%	23.78%	6.68%	0.392	1.18GB
whisper-small	244M	11.85% / 20.42%	8.31%	**18.43%**	**4.82%**	0.653	1.35GB
tenzin-small	244M	11.67% / 16.84%（自有混合域）	8.32%	**17.85%**	**4.54%**	0.472	1.34GB

关键观察：

1. **wav2vec2-base 的 CER 最低（7.25%）；词级质量最好的是 tenzin-small（SWER 17.85%）与 whisper-small（18.43%）——**与论文"CER 会低估词级错误"的结论一致。
2. 本机复现值与论文相差 0.2–4pp（普遍略好），差异主要来自文本规范化/参考转写版本，测试流程本身与论文一致（同 test split、同 3 说话人）。
3. **Whisper 的 448 token 上限**：藏文每字符约 3 个 byte-level token，因此单次最多输出约 145 字符。长句（>150 字）会被硬截断：whisper-small 在全部 300 条上 CER 8.31%，而在 ≤150 字的 245 条上只有 **4.82%**。生产环境必须对长音频切分。
4. RTF：CTC 模型快 20–40 倍；whisper-small 约 1.5 倍实时，300 条 35 分钟音频耗时 23 分钟。

2.2 OpenPecha 混合域基准（8 领域 × 20 条 = 160 条）

模型	CER	SWER	RTF	说明
wav2vec2-base（NICT 微调）	54.02%	93.12%	0.027	域外泛化失败
openpecha-general	**15.46%**	**38.27%**	0.060	与 OpenPecha 数据同源，可能训练集重叠，数值偏乐观
whisper-small（NICT 微调）	56.21%	89.60%	0.482	域外泛化失败
tenzin-small（混合域训练）	24.86%	46.85%	0.432	比 NICT 模型好，但仍逊于同源模型

openpecha-general 分领域 CER：

领域	有声书 AB	自然口语 NS	新闻 NW	播客 PC	开示 TT	电影 MV	历史 HS	儿童 CS
CER	**6.8%**	8.3%	11.2%	11.4%	13.1%	18.9%	20.3%	**33.7%**

关键观察：

1. **领域/口音匹配比模型结构更重要**：NICT（朗读新闻）上最强的 wav2vec2 换到混合域后 CER 从 7% 升到 54%，whisper-small 也从 8% 升到 56%；而多域训练的 openpecha-general 保持 15%，混合域训练的 tenzin-small 为 24.9%。
2. 儿童语音（33.7%~53.6%）和历史/电影类（19%~35%）是主要短板；有声书与自然口语最好（7%~14%）。

3. tenzin-small 的分领域 CER：有声书 14.0%、自然口语 13.9%、播客 14.8%、新闻 20.6%、开示 20.3%、历史 27.0%、电影 34.8%、儿童 53.6%。
4. 该基准与 openpecha 训练数据可能存在重叠，15.46% 应视为**乐观上界**；真实泛化需用完全独立的测试集。

2.3 失败模式

- 数字/专名：`ཉིས་སྟོང་`（2000）经常被识别成 `ཉིས་སྟོང་` / `ཉིས་མཐོ་`。
- 长句截断（Whisper）：输出在 145 字符附近戛然而止，参考 196 字符时 CER 直接 45%+。
- 域外音频（电影/儿童）：语法结构丢失，出现成段错译。

样例见 [`reports/samples/asr_samples.md`](reports/samples/asr_samples.md)，逐条指标在 `outputs/asr/<run_id>/predictions_scored.csv`。

---

3. 结论

需求	推荐	实测依据
藏文 OCR（生产）	**BDRC/tibetan-ocr（Yigdzin 1）**	60 页 mean CER 2.50%，中位 1.01%，0 灾难页，~33s/页，2.9GB 内存
藏文 OCR（极轻量兜底）	Tesseract + `bod`	8.6MB、3.3s/页，但 CER 53.5%
藏语 ASR（拉萨朗读、离线、低延迟）	**wav2vec2-base（NICT）**	CER 7.25%，RTF 0.023
藏语 ASR（词级质量优先）	**whisper-small（NICT）**	SWER 18.43%，短句 CER 4.82%
藏语 ASR（多领域/口语）	openpecha-general	混合域 CER 15.46%（注意许可与数据重叠）
商用合规	上述 Apache-2.0/CC-BY 模型；避开 `tenzin/*`（NC）与许可不明的 openpecha 模型	-

---

4. 复现

```
./scripts/run_all_ocr.sh           # OCR: Yigdzin + Tesseract, 60 页
./scripts/run_all_asr.sh           # ASR: 6 模型 × NICT + 4 模型 × OpenPecha
./.venv/bin/python scripts/summarize_asr.py --dataset both
./.venv/bin/python scripts/make_samples.py --ocr-run <run_id> --asr-run <run_id>
```