运行记录（Run Log）

日期：2026-11-12（北京时间）。所有命令在项目根目录执行，venv 为 `./.venv`。

1. 环境与数据

```
python3 -m venv .venv && ./.venv/bin/pip install -r requirements.txt
./.venv/bin/python scripts/prepare_ocr_data.py
./.venv/bin/python scripts/prepare_asr_data.py
./.venv/bin/python scripts/verify_data.py      # 数据完整性校验，全部通过
```

数据	结果	耗时
BDRC OCR 基准	472 页，导出 PNG + GT；官方 scorer 已下载	~10s（下载 121MB）
NICT-Tib1 test	1,547 条 / 185.5 分钟；3 说话人（074:800, 019:400, 070:347）；抽样 300 条	~40s（下载 335MB + 解码）
OpenPecha 基准	8 领域 × 20 = 160 条 / 8.9 分钟	~30s

2. OCR

run_id	引擎	页数	mean CER	median CER	灾难页	备注
`yigdzin_pilot_20261112_210826`	Yigdzin	3	4.41%	1.50%	0%	13.7s/页（含加载 41s 总计）
`tesseract_pilot_20261112_204458`	Tesseract	3	81.85%	78.30%	100%	0.5s/页
`yigdzin_sample_20261112_210922`	Yigdzin	60	**2.50%**	**1.01%**	0%	2184s；36.4s/页（后段与 ASR 并发，中位 33.3s）
`tesseract_sample_20261112_210924`	Tesseract	60	53.52%	56.06%	53.3%	198s；3.3s/页

命令：

```
./.venv/bin/python scripts/run_ocr.py --engine yigdzin --split pilot --limit 3 --use-dry
./.venv/bin/python scripts/run_ocr.py --engine tesseract --split pilot --limit 3
./.venv/bin/python scripts/run_ocr.py --engine yigdzin --split sample --use-dry
./.venv/bin/python scripts/run_ocr.py --engine tesseract --split sample
./.venv/bin/python scripts/score_ocr.py
```

关键调试记录：

- 初次运行 Yigdzin 单页 >5 分钟未出结果 → 定位为 `generation_config.use_cache=false`；显式 `use_cache=True` 后 120 token 从 83.4s 降到 7.5s，且输出逐字节一致。
- 模型卡要求 `mm_token_type_ids` 清零，已实现。

- DRY 抗重复（mult=0.8/base=1.75/allowed_length=12）全程开启，未出现循环。

3. ASR

run_id	模型	数据集	n	CER	SWER	RTF
`wav2vec2-base_nict_20261112_212254`	wav2vec2-base	NICT 全量	1547	7.90%	29.81%	0.023
`openpecha-general_nict_20261112_212842`	openpecha-general	NICT 全量	1547	8.28%	30.19%	0.049
`whisper-tiny_nict_20261112_214708`	whisper-tiny	NICT 300	300	11.57%	27.84%	0.251
`whisper-base_nict_20261112_215613`	whisper-base	NICT 300	300	10.22%	23.78%	0.392
`whisper-small_nict_20261112_221057`	whisper-small	NICT 300	300	8.31%	18.43%	0.653
`tenzin-small_nict_20261112_223457`	tenzin-small	NICT 300	300	8.32%	17.85%	0.472
`wav2vec2-base_openpecha_20261112_221718`	wav2vec2-base	OpenPecha	160	54.02%	93.12%	0.027
`openpecha-general_openpecha_20261112_221753`	openpecha-general	OpenPecha	160	15.46%	38.27%	0.060
`whisper-small_openpecha_20261112_225427`	whisper-small	OpenPecha	160	56.21%	89.60%	0.482
`tenzin-small_openpecha_20261112_225857`	tenzin-small	OpenPecha	160	24.86%	46.85%	0.432

命令（与 `scripts/run_all_asr.sh` 一致）：

```
./scripts/run_all_asr.sh
./.venv/bin/python scripts/summarize_asr.py --dataset both
```

关键调试记录：

1. `billingsmoore/*-whisper-*` 仓库只含 `config.json + model.safetensors`，没有 tokenizer/preprocessor → 用 `openai/whisper-{tiny,base,small}` 的 processor 重建。
2. transformers 5.22 的 Whisper 长格式生成（仅给 `max_length`）会触发 `EncoderDecoderCache has no attribute layers` → 显式传 `max_new_tokens` 走短格式。
3. `max_new_tokens` 在该版本被当作总长度处理（`seq.shape == max_new_tokens`），因此取 440（上限 448）。
4. 藏文 byte-level token ≈ 3 token/字符 → Whisper 单次最多 ~145 字符；长句截断导致 CER 虚高，故同时报告 ≤150 字子集。
5. 初次 10 条 pilot 的 CER 47% 是长句偏置造成的假象，扩大到 300 条分层样本后为 11.6%。

4. 汇总产物

- `reports/ocr_results.csv`、`reports/ocr_per_page.csv`
- `reports/asr_results.csv`、`reports/asr_final_{nict,openpecha,both}.csv`
- `reports/samples/ocr_samples.md`、`reports/samples/asr_samples.md`（含图片/音频）
- `reports/environment.txt`